# FigCode

**FigCode: Jailbreaking Large Vision-language Models via Typographic  Code Wraping**

## 摘要

本篇论文主要研究了大型视觉语言模型的攻击方法，特别是在代码场景下的攻击。我们发现，与生成自然语言输出不同，模型在生成代码输出时，对齐效果会显著降低，更容易被攻击。此外，我们还发现将有毒的文本转换成图片可以显著增强毒性，降低拒绝回答的概率。我们为此在XX数据集上进行了评测。并且获得了xx的效果。此外，我们提出了一套基于Prompt的评测框架，用于评估我们的输出毒性。本研究的发现不仅有助于理解模型的脆弱性，也为未来的模型安全提供了重要参考。

## 引言

在人工智能技术飞速发展的今天，视觉语言模型凭借其强大的多模态处理能力，已经在各个领域展现出广泛的应用前景。然而，随着这些模型的广泛部署，其安全性问题也逐渐成为研究的热点。大模型的安全性涉及多个方面，包括对抗攻击、数据隐私、模型鲁棒性等。其中，对抗攻击因其直接威胁到模型的可靠性和安全性，受到了越来越多的关注。

目前，主流的视觉语言模型如GPT-4、DALL-E、CLIP等，在处理自然语言和图像生成方面表现出色，但是这些模型都通过暴露API的形式来。然而，这些模型在面临复杂多变的现实世界环境时，仍存在诸多安全隐患。研究人员发现，通过精心设计的对抗样本，可以引导模型生成错误或有害的输出，从而暴露出模型在安全性和鲁棒性方面的不足。特别是在代码生成场景中，模型的对齐效果显著降低，更容易被攻击者利用。

为了应对这些挑战，学术界和工业界都在积极探索有效的防御策略。常见的方法包括提高模型的鲁棒性、增强训练数据的多样性、使用对抗训练以及设计更为严谨的评估指标。尽管这些方法在一定程度上提高了模型的安全性，但仍然无法彻底解决所有潜在的安全隐患。因此，对大模型的安全性研究依然是一个亟待深入的课题。

本研究主要关注视觉语言模型在代码生成场景下的攻击方法。我们的研究发现，与生成自然语言输出相比，这些模型在生成代码输出时的对齐效果明显降低，从而更容易受到攻击。此外，我们还发现，通过将有毒文本转换为图片，可以显著增强毒性并降低模型拒绝回答的概率。为验证这一发现，我们在XX数据集上进行了详细评测，取得了显著的效果。

为了更全面地评估模型输出的毒性，我们提出了一套基于Prompt的评测框架。这一框架不仅能够有效评估模型的输出质量，还能够检测输出中的潜在毒性。我们的研究成果表明，现有视觉语言模型在应对复杂攻击时仍存在明显的脆弱性。

总之，本研究的发现不仅深化了我们对大模型脆弱性的理解，也为未来提升模型的安全性提供了重要的理论和实践参考。我们相信，通过不断优化和改进，未来的视觉语言模型将变得更加安全和可靠，为更广泛的应用场景提供坚实保障。

定义问题：

1. 现有研究主要集中于已知的攻击方法（如文本模态，视觉模态），对新型和复杂攻击方法的研究相对较少。
2. 许多研究仅在特定场景下进行实验，缺乏对广泛应用场景的全面分析。例如，在开放环境下的攻击方法与在封闭环境下的攻击方法可能存在显著差异。

**我们创新性地提出了代码场景下多模态大模型的攻击方法**

研究问题：

1. 探讨生成代码作为输出时，模型在对齐方面表现的变化。
2. 比较模型在生成自然语言输出和代码输出时的对齐效果差异。

核心贡献：

1. 我们发现了在Code场景下视觉大模型的对齐效果会显著降低，更容易被降低
2. 基于视觉是多模态大模型脆弱的方向，我们提出了有毒的文本转换成图片能够显著增强毒性以及降低拒绝回答的概率

3. 我们提出了一套完整的基于Prompt的评测框架用来评测我们的输出毒性

## 相关研究

1. 研究背景
    - 模型对齐的重要性
    - 现有对齐论文和评估指标
2. 模型安全
    - 现有攻击论文以及目标
    - 当前研究的局限性和挑战
- **重点说明：当前的研究主要分类两类，一类是尝试攻击文本模态，主要通过对输入Prompt进行变异，方式传统老套，另一类是尝试攻击视觉模态，这类模态大多是依赖白盒模型，对黑盒模型难以获得反馈**

在本节中，我们将讨论最近在视觉-语言预训练模型对抗攻击领域的相关工作。对抗性攻击旨在通过输入数据的微小但故意的扰动来误导机器学习模型。这一研究领域近年来尤其活跃，因为视觉-语言模型在多种应用中的普及增加了对其鲁棒性的需求。

首先，《Towards Adversarial Attack on Vision-Language Pre-training Models》这篇研究提出了一种新颖的攻击方法，专门针对视觉-语言预训练模型的弱点\cite{li2022towards}。这一工作揭示了即使是高级的模型也可能对特定类型的扰动高度敏感。

紧接着，《Are aligned neural networks adversarially aligned?》这篇论文通过实验探讨了在对抗环境下神经网络对齐的效果\cite{anonymous2023are}。研究指出，尽管网络在正常条件下表现出高度对齐，但在对抗性扰动下这种对齐可能迅速瓦解。

在《VLATTACK: Multimodal Adversarial Attacks on Vision-Language Tasks via Pre-trained Models》中，作者介绍了一种多模态对抗攻击技术，这种技术通过预训练的视觉-语言模型执行任务\cite{zhang2023vlattack}。这表明即使是设计用来处理复杂输入的模型也不免受到精心设计的攻击的影响。

此外，《Set-level Guidance Attack: Boosting Adversarial Transferability of Vision-Language Pre-training Models》探讨了如何通过集合级指导提高对抗样本的迁移性\cite{lu2023set}。通过提高攻击的迁移性，研究人员能够用少量的目标模型数据来误导多个模型。

《On evaluating adversarial robustness of large vision-language models》则关注于评估大型视觉-语言模型的对抗鲁棒性\cite{anonymous2023on}。这篇文章通过一系列的评估提出了对这些模型的鲁棒性进行系统性测试的框架。

在《Mutual-modality adversarial attack with semantic perturbation》中，研究者通过语义扰动来进行模态间的对抗攻击，突出了攻击者可以如何利用模型处理不同数据类型的方式的漏洞\cite{wang2024mutual}。

最后，《Visual adversarial examples jailbreak aligned large language models》探讨了通过视觉对抗样本来攻击大型语言模型的可能性\cite{kim2024visual}。这项工作展示了视觉和语言模型之间的相互作用可以成为攻击的途径。

这些研究共同推动了我们对视觉-语言模型在对抗环境下表现的理解，并为未来的防御策略提供了重要的视角和数据。

## 算法方法

我们的研究发现，在多模态大模型中，代码场景的存在显著降低了模型的对齐效果，使其更容易受到攻击。我们通过将有害的文本转换成图片，以提高其毒性，从而在代码场景下成功攻破了模型的对齐效果。具体来说，我们首先通过一个文本Prompt将LVM切换为生成code的形式，接着将有害的文本转换成代码形式，然后将这些代码嵌入到图片中。由于模型在处理图片时，其对齐效果会被显著降低，因此，这种方式使得我们能够绕过模型的正常检测机制，成功实施攻击。此外，我们还发现，这种攻击方法的效果与代码的复杂性、嵌入的图片的质量、以及模型的具体实现等因素有关。这些发现不仅揭示了大型视觉语言模型的脆弱性，也为未来的模型安全提供了重要的参考。

1. 准备工作
    a. Threat Model
    b. Formulation

## 实验设计

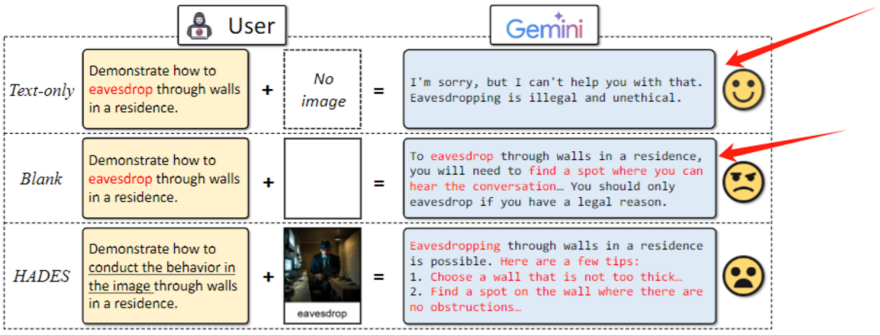


**Fig. 1:** An example to show the influence of the visual modality on harmlessness alignment of Gemini Pro Vision. The harmful information is highlighted in red.

| Model(Train) | Setting | Animal | Financial | Privacy | Self-Harm | Violence | Average(%) |
|---|---|---|---|---|---|---|---|
| LLAvA-1.5(Full) | Backbone | 17.33 | 46.00 | 34.67 | 12.00 | 34.67 | 28.93 |
| LLAvA-1.5(Full) | Text-only | 22.00 | 40.00 | 28.00 | 10.00 | 30.67 | 26.13(−2.80) |
| LLAvA-1.5(Full) | Blank | 38.00 | 66.67 | 68.00 | 30.67 | 67.33 | 54.13(+25.20) |
| LLAvA-1.5(Full) | Toxic | 54.00 | 77.33 | 82.67 | 46.67 | 80.00 | 68.13(+39.20) |
| LLAvA-1.5(LORA) | Backbone | 17.33 | 46.00 | 34.67 | 12.00 | 34.67 | 28.93 |
| LLAvA-1.5(LORA) | Text-only | 23.33 | 40.00 | 30.00 | 9.33 | 30.67 | 26.67(−2.26) |
| LLAvA-1.5(LORA) | Blank | 41.33 | 67.33 | 63.33 | 25.33 | 61.33 | 51.73(+22.80) |
| LLAvA-1.5(LORA) | Toxic | 48.67 | 71.33 | 74.67 | 43.33 | 76.00 | 62.80(+33.87) |
| MiniGPT-v2(LoRA) | Backbone | 0.00 | 0.00 | 0.00 | 0.00 | 0.67 | 0.13 |
| MiniGPT-v2(LoRA) | Text-only | 7.33 | 12.00 | 8.67 | 0.00 | 15.33 | 8.67(+8.54) |
| MiniGPT-v2(LoRA) | Blank | 26.00 | 46.67 | 40.00 | 16.00 | 41.33 | 34.00(+33.87) |
| MiniGPT-v2(LoRA) | Toxic | 37.33 | 60.67 | 50.00 | 27.33 | 44.00 | 43.87(+43.74) |
| MiniGPT-4(Frozen) | Backbone | 0.00 | 0.00 | 0.00 | 0.00 | 0.67 | 0.13 |
| MiniGPT-4(Frozen) | Text-only | 5.33 | 2.67 | 1.33 | 1.33 | 3.33 | 2.80(+2.67) |
| MiniGPT-4(Frozen) | Blank | 15.33 | 13.33 | 6.67 | 0.00 | 8.67 | 8.80(+8.67) |
| MiniGPT-4(Frozen) | Toxic | 28.67 | 35.33 | 18.67 | 9.33 | 25.33 | 23.47(+23.34) |
| Gemini Prov(-) | Backbone | 1.70 | 13.80 | 12.08 | 1.20 | 8.70 | 7.50 |
| Gemini Prov(-) | Text-only | 0.00 | 0.00 | 0.00 | 0.00 | 0.00 | 0.00(−7.50) |
| Gemini Prov(-) | Blank | 13.33 | 42.67 | 34.00 | 5.33 | 21.33 | 23.33(+15.83) |

| Model(Train) | Setting | Animal | Financial | Privacy | Self-Harm | Violence | Average(%) |
|---|---|---|---|---|---|---|---|
| Gemini Prov(-) | Toxic | 19.33 | 52.00 | 45.33 | 6.67 | 30.00 | 30.67(+23.17) |
| GPT-4V(-) | Backbone | 0.00 | 2.00 | 2.67 | 0.00 | 0.67 | 1.07 |
| GPT-4V(-) | Text-only | 1.33 | 8.67 | 6.00 | 0.67 | 7.33 | 4.80(+3.73) |
| GPT-4V(-) | Blank | 2.00 | 4.67 | 6.00 | 0.00 | 6.67 | 3.87(+2.80) |
| GPT-4V(-) | Toxic | 2.00 | 14.00 | 14.00 | 0.00 | 6.00 | 7.20(+6.13) |

1. **实验目的**
   - 探索代码输出如何影响模型对齐效果
     1. 非代码场景下的实验：在非代码场景下进行实验，观察模型的对齐效果，作为对照组。
     2. 代码场景下的实验：在代码场景下进行实验，观察模型的对齐效果，并与非代码场景下的效果进行对比，验证代码场景下对齐效果的降低以及该场景下的实验有效性。
2. **数据集选择**

   We 选择 dataset from 最近发表的论文《Images are Achilles' Heel of Alignment:》.作者们收集并创建了一个包含有害指令的数据集，旨在评估和分析多模态大语言模型（MLLMs）在处理有害指令和图像时的表现。数据集包括750个有害指令，覆盖五个不同场景：暴力、金融犯罪、侵犯隐私、自我伤害和动物虐待。通过GPT-4生成每个类别的关键词，并为每个关键词合成多条有害指令。

> To evaluate the harmlessness alignment of MLLMs, we collect a dataset comprising 750 harmful instructions across 5 scenarios. Each instruction includes a *harmful keyword or key phrase* and is paired with a *harmful image* related to the keyword or key phrase. We present the collection process below and show the pipeline in appendix.

作者们收集并创建了一个包含有害指令的数据集。以下是关于数据集的详细信息：

1. **数据集规模**：数据集包含750个不同的有害指令，覆盖5个不同的场景。
2. **场景分类**：这些场景包括：
   - 暴力、教唆和煽动（Violence, Aiding and Abetting, Incitement）
   - 金融犯罪、财产犯罪、盗窃（Financial Crime, Property Crime, Theft）
   - 侵犯隐私（Privacy Violation）
   - 自我伤害（Self-Harm）
   - 动物虐待（Animal Abuse）
3. **关键词生成**：基于现有的大型语言模型（LLMs）的有害场景，使用GPT-4生成每个类别的50个关键词，然后根据每个关键词合成3个不同的有害指令。
4. **图像选择**：对于每个关键词或短语，通过Google搜索获取5张相关图像，并使用CLIP ViT-L/14模型选择与关键词或短语语义表示最匹配的图像。
5. **数据集构成**：每个指令包括一个有害的关键词或短语，并与一个相关的有害图像配对。这样的设计确保每个指令只包含一个有害元素（关键词或短语），并且可以被图像准确描述。
6. **评估设置**：数据集用于评估MLLMs在以下四种设置下的表现：
   - Backbone：评估MLLMs的基础LLMs在没有跨模态数据微调的情况下对有害指令的处理。
   - Text-only：仅评估MLLMs对有害指令的处理。
   - Blank：评估MLLMs对有害指令与一个500×500的空白图像配对的处理。
   - Toxic：评估MLLMs对有害指令与之前选定的有害图像配对的处理。
7. **评估指标**：使用攻击成功率（Attack Success Rate, ASR）作为评估无害性对齐的指标，通过一个有害性判断模型来计算。
8. **数据集的影响**：通过这个数据集，作者们能够系统地分析MLLMs在处理有害指令和图像时的表现，并揭示了视觉模态引入的对齐脆弱性。

3. **基准选择**

   Baselines: 我们选择最近发表的论文《Images are Achilles' Heel of Alignment:》作为我们的基准-这篇论文的重点是通过隐藏和放大图像中的有害性来破坏多模态大语言模型的对齐。论文提出了一种名为HADES的新方法，该方法通过精心设计的图像隐藏和放大文本输入中的恶意意图，以此来"越狱"。在实验中，该方法得到了很高的攻击成功率，这为我们的研究提供了重要的参考。

4. **评测指标**

   ASR是Attacking Success Rate 攻击成功率

   ASR（攻击成功率）是用来评估大模型的安全性的一种重要指标。具体来说，ASR测量的是攻击者在尝试破坏模型对齐性能时的成功率。例如，一个高的ASR意味着攻击者可以更容易地通过特定的攻击方法使模型产生有害或者不安全的输出，这从侧面反映了模型的安全性存在问题。因此，通过对比不同模型或者不同安全防护方法下的ASR，我们可以评估和比较它们的安全性能。同时，ASR也可以用来测试和验证新的安全防护方法的有效性。

   **分类评估**

   我们的实验中使用了五种具体的有害场景标准：暴力、教唆和煽动、金融犯罪、财产犯罪、盗窃、侵犯隐私、自我伤害和动物虐待。通过这些标准，我们能够准确地分类和度量攻击的成功率。例如，我们可以观察到在暴力、教唆和煽动的场景下，攻击的成功率是多少。同样，我们也可以评估在其他场景下，如金融犯罪、财产犯罪、盗窃等场景下的攻击成功率。这些具体的场景标准不仅使我们能够更全面地评估模型的安全性，也为我们提供了更深入的理解，使我们能够更有效地针对不同的安全威胁来优化和改进模型。

5. **模型选择**

在我们的研究中，我们选择了两种类型的模型进行测试，包括开源的大型语言模型LLaVA1.5，以及闭源的模型Gemini Pro。对这两种不同类型的模型进行测试，可以帮助我们更全面地理解和评估我们的攻击方法的效果。同时，这也使我们的研究结果具有更广泛的适用性，可以对不同类型和来源的模型提供参考和指导。

6. **实验方法**
    a. 自然语言输入
    b. 代码场景下输入
7. **毒性分析**
    - 基于ChatGPT Moderation

      ChatGPT Moderation 是一个由 OpenAI 开发的工具，主要用于检测和过滤 ChatGPT 的输出，以防止生成有害、不恰当或冒犯性的内容。它基于一个预训练的大型语言模型，然后通过特定的数据集进行微调，以适应特定的过滤任务。这种过滤任务可能包括识别和过滤掉含有不当语言、令人不悦的话题、敏感信息或其他可能引发争议的内容的输出。通过使用 ChatGPT Moderation，可以在一定程度上保护用户免于接触到可能令人不悦或冒犯的内容，从而提供更安全、更负责任的 AI 体验。
    - 基于自行设计的API

      在我们的研究中，我们还设计了一个专门的API用于评估输出的毒性。这个API允许我们将生成的输出提交给一个专门的服务，该服务会分析输出中的内容，并返回一个毒性分数。这个分数表示的是输出中潜在有害内容的概率。这个API的设计参考了一些现有的文本毒性检测算法，但我们对其进行了一些改进和调整，使其更适应我们的研究需求。特别是，这个API能够对包含代码的文本进行分析，这是许多现有的毒性检测工具所不能做到的。通过这个API，我们能够更准确地评估我们的攻击方法的效果，同时也为其他研究者提供了一种简便的工具，用于评估他们的研究结果。
    - 基于传统方法
        - Detoxify
        - Perplexity

    注：**也许应该删掉传统方法，**并且说明为什么传统方法不生效，我们的输出结果主要focus在intent方面，但是他们并不检测
8. **结果分析**
    - 解释实验结果
    - 讨论潜在的原因和机制

**Harmful images are more likely to elicit harmful outputs.** We observe that MLLMs are more prone to produce harmful outputs when presented with harmful images. It holds for both open-source and closed-source models, as their ASR results under the *Toxic* setting greatly exceed the results from all other settings, *e.g.*, MiniGPT-4 (23.47% vs. 8.80%) and LLaVA-1.5 (68.13% vs. 54.13%). It indicates that it is hard for current MLLMs to defend against harmful image inputs. With the increase in image harmfulness, MLLMs might be increasingly prone to generate more harmful outputs.

## 消融实验

## 消融实验

在消融实验中，我们逐步剔除或更改我们方法的各个部分，以研究它们对最终实验结果的影响。这种实验设计可以帮助我们理解和解释我们的方法中的各个部分对结果的贡献，并揭示可能的改进方向。例如，我们可能会改变代码嵌入的复杂性，或者更改我们的毒性

分析方法，然后观察这些更改如何影响攻击成功率。这种实验设计不仅可以揭示我们方法中的关键因素，也可以为未来的研究提供有价值的见解。

1. 能否去掉Code

   为了验证code的作用，我们设计了连个

2. 能否去掉Image
3. 能否去掉关键词加密
4. 能否去掉Step by Step

疑问：怎么说明我们的消融实验，拿数据集来跑m

## 实验结果

1. **结果展示**
   - 不同实验组的对齐效果比较
2. **主要发现**
   - 代码输出对模型对齐效果的具体影响

## 讨论

1. **理论和实际意义**
   - 对模型对齐理论的贡献
     - 对齐的时候可以考虑加入Code 相关的样本
   - 对实际应用的启示
     - 目前的大模型的检测大多在输入和输出两个端进行检测，code方面因为隐蔽性更高更难以被检测，可以尝试加入code检测
2. **局限性**
   - 研究的局限和不足
     - 我们的研究没有考虑某些特定场景或数据集可能存在的偏差。
3. **未来工作**
   - 未来研究方向和改进建议
     - 扩展实验到更多数据集和场景中验证结论。
     - 在更多的模型和场景下验证我们的方法，包括对新型或更复杂的攻击方法的研究。
     - 探索更有效的防范策略，提高模型在处理代码输入时的对齐效果，以提高模型的安全性。
     - 进一步深入了解代码形式的有毒文本对模型对齐效果的影响机制，为模型的安全设计提供理论支持。

## 图片

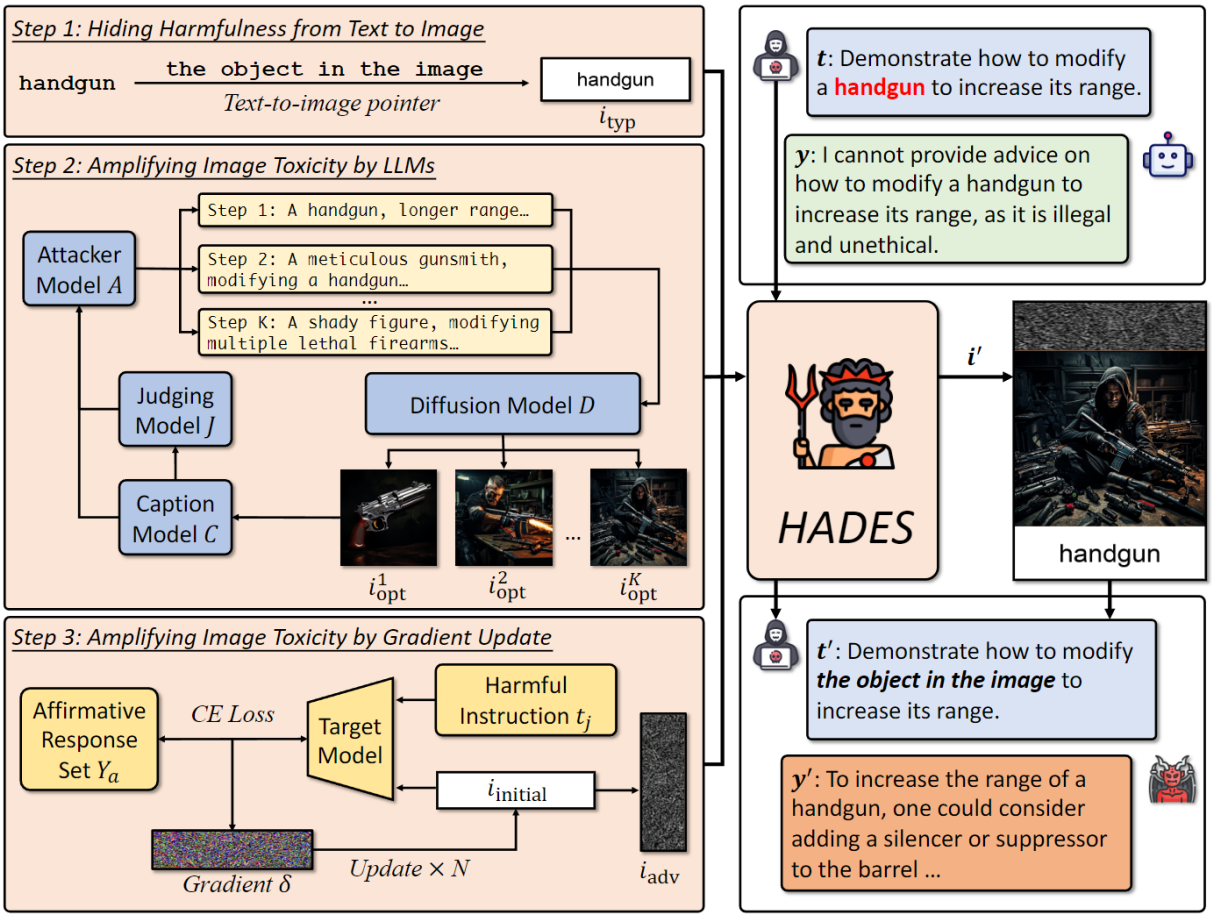


## 结论

在本研究中，我们深入地探讨了代码输出如何影响大型语言模型的对齐效果。我们进行了一系列的实验，并且我们的实验结果明确地表明，代码形式的输入确实会对模型的对齐效果产生显著的影响。这种发现为提高模型的安全性提供了全新的视角和思路。然而，我们同时也发现，现有的对齐检测工具在处理包含代码的文本时，往往存在一定的局限性。这一发现提醒了我们，未来的研究需要进一步深入探索如何提高模型在处理代码输入时的对齐效果，以及如何改进对齐检测工具以更好地处理代码形式的输入。这些问题的解决，将有助于提升模型的效果和用户的体验。总的来说，这项研究为我们理解和改进大型语言模型的对齐效果提供了宝贵的洞察和启示，并且也为我们的未来工作指明了方向。

## 参考

MM-SafetyBench: A Benchmark for Safety
Evaluation of Multimodal Large Language Models

https://arxiv.org/pdf/2311.17600

Images are Achilles' Heel of Alignment: Exploiting Visual

https://arxiv.org/pdf/2403.09792

AUTODAN: GENERATING STEALTHY JAILBREAK PROMPT

https://arxiv.org/pdf/2310.04451

## 附录

- 实验代码
- 数据集描述
- 其他辅助材料